```
import pandas as pd
import numpy as np
import numpy.linalg as la
from sklearn.preprocessing import StandardScaler
import statsmodels.formula.api as smf
import statsmodels.api as sm
import matplotlib.pyplot as plt
from scipy.stats import t
```

Parcial 1: Estadística en Analítica

Por Alejandro Velásquez Arango

Universidad EAFIT

07/05/2022

Punto 1

Model:

Date:

Time:

Method:

```
In [ ]:
       df = [
          [-2, 0],
          [-1, 0],
          [0, 1],
          [1, 1],
          [2, 3]
       df = pd.DataFrame(df, columns="X Y".split())
Out[ ]:
         X Y
      0 -2 0
      1 -1 0
        0 1
        1 1
         2 3
In [ ]:
       lm = smf.ols('Y~X', df)
       lm_fit = lm.fit()
       print(lm fit.summary())
                            OLS Regression Results
      _____
      Dep. Variable:
                                      R-squared:
                                                                0.817
```

OLS

Least Squares

12:04:32

Sat, 07 May 2022

Adj. R-squared:

Log-Likelihood:

Prob (F-statistic):

F-statistic:

0.756

13.36

0.0354

-3.3094

No. Observations: 5 AIC: 10.62 Df Residuals: 3 BIC: 9.838 Df Model: 1 Covariance Type: nonrobust ______ std err t coef P>|t| [0.025 0.9751 1.0000 0.271 0.034 Intercept 3.693 0.138 1.862 0.7000 0.191 0.035 0.091 3.656

1.309 ______ 2.509 Omnibus: nan Durbin-Watson: Prob(Omnibus): nan Jarque-Bera (JB): 0.396 Prob(JB): Skew: -0.174 0.821 Cond. No. Kurtosis: 1.667 1.41 ______

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

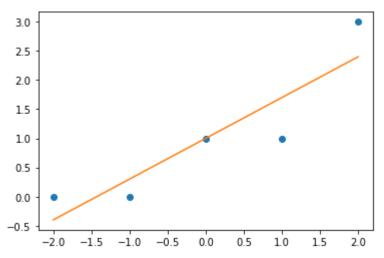
c:\Users\lenovo\anaconda3\lib\site-packages\statsmodels\stats\stattools.py:74: ValueWarn
ing: omni_normtest is not valid with less than 8 observations; 5 samples were given.
 warn("omni_normtest is not valid with less than 8 observations; %i "

Con statsmodels, se obtiene el modelo de regresión lineal:

$$Y = 1 + 0.7X$$

Los mismos coeficientes se pueden obtener de manera matricial, resolviendo la ecuación

$$\beta = \left(X^T X\right)^{-1} X^T Y$$



Cuando X=1, el valor esperado de Y es

$$Y = 1 + 0.7(1) = 1.7$$

Out[]: 0.36666666666666

Para X=2, se tiene $a^T=[1,\ 2]$. El intervalo de confianza de Y viene dado por:

$$a^T \hat{eta} \pm t_{lpha/2} S \sqrt{1 + a^T (X^T X)^{-1} a}$$

```
In [ ]:
# El 1 del primer valor del vector corresponde al intercepto
a = np.array([1, 2])
P = la.inv(X.T @ X)
var_y = S2 * (1 + a.T @ P @ a)
var_y
```



```
# El 1 del primer valor del vector corresponde al intercepto
lower_bound_y = a.T @ betas - t.ppf(0.975, df = len(Y) - len(betas)) * np.sqrt(var_y)
upper_bound_y = a.T @ betas + t.ppf(0.975, df = len(Y) - len(betas)) * np.sqrt(var_y)
lower_bound_y, upper_bound_y
```

Out[]: (-0.03756828932652212, 4.837568289326523)

El intervalo de confianza para la predicción de Y con X=2 es:

```
[-0.037, 4.837]
```

Punto 2

Carga de datos

```
In [ ]:
    df = pd.read_csv('../datos/paises.csv')
    df.tail()
```

```
Out[ ]:
             X1
                                   X5
                 X2 X3
                            X4
                                       X6
                                            X7 X8 X9
                                                         X10 X11
            2.4
                         65382 73116 111
         91
                  23 33
                                            382
                                                52 1.2
                                                        2186
                                                               5.7
            2.2
                  41 49
                         17634 12270
                                        11 414
                                                26 1.5
                                                          101
                                                               0.3
                          4044
            4.2 100
                    29
                                 2159
                                        12 335
                                                  8 0.0
                                                          206
                                                               0.7
            2.6 109 45
                           3605
                                 7785
                                         8
                                           186
                                                43 1.1
                                                          149
                                                               0.3
         95
            2.8
                  55 44
                           5933
                                 7334
                                        14 136 23 0.7
                                                         438
                                                               1.8
```

Se calcula primero la matriz de covarianzas y se obtiene su inversa

```
In [ ]: S = df.cov()
S_inv = la.inv(S)
```

```
In [ ]:
    R2 = 1 - 1/(np.diag(S)*np.diag(S_inv))
    print(df.columns)
    R2.round(2)
```

```
Index(['X1', 'X2', 'X3', 'X4', 'X5', 'X6', 'X7', 'X8', 'X9', 'X10', 'X11'], dtype='object') array([0.68, 0.68, 0.64, 0.67, 0.63, 0.82, 0.3, 0.19, 0.22, 0.87, 0.81])
```

Calculando el los coeficientes de correlación múltiples y obteniendo $R^2=1-\frac{1}{S^{ij}S_{jj}}$, se puede determinar que la variable que mejor se puede explicar en términos de las otras es X_{10}

PCA

Primero, los datos deben estar estandarizados para se tenga media 0 y desviación 1

Se obitene las autovectores y autovalores de la matriz de covarianza

```
df_stand = StandardScaler().fit_transform(df)
print(df_stand.mean(axis=0))
print(df_stand.std(axis=0))
```

```
[-1.85037171e-16 3.70074342e-17 3.70074342e-17 -2.77555756e-17 -3.23815049e-17 0.00000000e+00 -9.25185854e-18 7.86407976e-17
```

```
0.00000000e+00 2.77555756e-17 5.55111512e-17]
        [1. 1. 1. 1. 1. 1. 1. 1. 1. 1. 1.]
       Ahora se calcula la matriz de covarianza de los datos estandarizados
In [ ]:
         S = np.cov(df_stand.T)
         eig values, eig vectors = la.eig(S)
         print(eig values.round(2))
         print(eig vectors.round(2))
         [4.07 1.95 1.38 0.07 0.15 0.17 0.33 0.58 0.87 0.8 0.74]
         [[ 0.31 -0.35 -0.07 -0.1
                                  0.35 0.52 0.09 -0.16 0.44 0.33 -0.18]
         [ 0.39  0.04 -0.18  0.17 -0.39 -0.29  0.32 -0.64  0.13 -0.08 -0.09]
         [-0.12 0.58 0.17 -0.17 0.43 0.24 -0.05 -0.53 -0.06 -0.19 0.17]
         [-0.3
                 0.18 -0.53 -0.15 0.35 -0.37
                                               0.45 0.15 0.26 0.14 0.05]
         [-0.26 0.17 -0.61 0.12 -0.34 0.31 -0.5 -0.11 0.17 0.08 0.03]
         [-0.45 0.03 0.15 0.45 -0.21 0.45 0.57 0.
                                                           -0.05 0.05 0.02]
         [-0.09 -0.32 -0.37 -0.07 0.21 0.08 0.06 -0.24 -0.74 -0.03 -0.31]
         [-0.01 0.46 0.16 -0.01 -0.09 -0.07 -0.04 0.08 -0.04 0.42 -0.75]
         [ 0.24  0.15  -0.03  0.07  -0.03  -0.02  0.02  -0.01  -0.34  0.73  0.51]
         [-0.42 -0.23  0.21 -0.68 -0.36 -0.04  0.05 -0.27  0.07  0.23  0.06]
         [-0.37 -0.29 0.21 0.47 0.29 -0.38 -0.31 -0.34 0.15 0.24 -0.03]]
In [ ]:
         print(eig values[0]/eig values.sum().round(2))
         print(eig values[1]/eig values.sum())
        0.36621392092378485
        0.17545381348370237
        Se seleccionan los dos primeros autovalores que son los que tienen mayor valor: \lambda_1=4.07 y
       \lambda_2 = 1.95
In [ ]:
         new df = []
         for index, row in enumerate(df stand):
             new_df.append([np.dot(eig_vectors[:,0], row), np.dot(eig_vectors[:,1], row)])
         new df = pd.DataFrame(np.array(new df), columns="Z1 Z2".split())
         new df.tail()
Out[]:
                 Z1
                          Z2
        91 0.165907
                     0.114074
        92 1.366391
                     1.072347
        93 2.599022 -1.350077
        94 2.340780
                     1.230173
        95 1.505448
                    0.447563
In [ ]:
         new df.iloc[13]
             -2.465597
        Z1
Out[ ]:
```

Para el registro $x^{(13)}$, las componentes en el plano de Z_1 y Z_2 son (-2.46, 1.02)

Z2 1.024444
Name: 13, dtype: float64

Para saber cual es la variable que más aporta en el componente principal \mathbb{Z}_2 , se debe observar el autovector asociado

```
In [ ]:
         print(df.columns)
         print(eig vectors[1].round(2))
         Index(['X1', 'X2', 'X3', 'X4', 'X5', 'X6', 'X7', 'X8', 'X9', 'X10', 'X11'], dtype='objec
         [ 0.39  0.04 -0.18  0.17 -0.39 -0.29  0.32 -0.64  0.13 -0.08 -0.09]
        La variable que más aporta al componente principal Z_2 es X_8, con un coeficiente de -0.64
In [ ]:
          plt.plot(new_df.Z1, new_df.Z2, 'o')
         plt.xlabel("Z1")
         plt.ylabel("Z2")
        Text(0, 0.5, 'Z2')
Out[]:
            2
            0
         R -2
           -6
                  -5
                                               Ó
                                                    i
                                                          ż
                                   -2
                                        -1
```

A partir de la gráfica, se puede observar un outlier alrededor de (-3, 3)

Punto 3

```
0 -2 0 0
1 -1 0 1
2 0 1 1
```

	X1	X2	Y
3	1	1	0
4	2	3	1

La función de pérdida de un modelo de regresión logística viene dada por:

$$L = rac{1}{m} \sum_{i}^{m} \left[-Y^{(i)} \cdot \ln \Bigl[g(X^{(i)} \cdot eta) \Bigr] - (1 - Y^{(i)}) \left(1 - \ln \Bigl[g(X^{(i)} \cdot eta) \Bigr]
ight)
brace$$

donde

$$g(X\cdoteta)=rac{1}{1+e^{-(X\cdoteta)}}=rac{1}{1+e^{-(eta_0+eta_1X)}}$$

Ajustemos los datos a un modelo de regresión logística y determinemos la predicción para el punto $(0,\ 2)$

Optimization terminated successfully.

Current function value: 0.601406

Iterations 6

```
In [ ]: print(lr_fit.summary())
```

Logit Regression Results No. Observations: Dep. Variable: Model: Logit Df Residuals: 3 Df Model: 1 Method: MLE Date: Sat, 07 May 2022 Pseudo R-squ.: 0.1064 Time: 12:04:37 Log-Likelihood: -3.0070 converged: True LL-Null: -3.3651 nonrobust LLR p-value: 0.3974 Covariance Type: coef X1 0.0406 0.855 0.047 0.962 1.716 1.012 0.6684 0.660 0.509

Out[]: 0.7919551575395981

Como el valor es mayor a 0.5, se dice que la clase predicha para el punto (0, 2) es 1