Parcial 2: Estadística en Ciencia de Datos

Alejandro Velásquez Arango

EAFIT 2022

```
import pandas as pd
import numpy as np
import numpy.linalg as la
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler, MinMaxScaler
from scipy.spatial.distance import euclidean
import matplotlib.pyplot as plt
```

Punto 1

```
In [ ]:
            df1 = pd.read_excel('./../datos/Paises2.xlsx', index_col='Pais')
            df1
Out[]:
                               X1
                                    X2 X3
                                                            X5
                                                                  X6
                                                                         X7
                                                                             X8
                                                                                    X9
                                                                                         X10
                                                                                              X11
                                                   X4
                       Pais
                               1.0
                                                 2199
                                                          3903
                                                                                                 1.2
                   Albania
                                     30
                                          41
                                                                  12
                                                                         94
                                                                              53
                                                                                    0.0
                                                                                          341
                    Angola
                               3.0
                                    124
                                          46
                                                 4422
                                                           955
                                                                   6
                                                                         57
                                                                              19
                                                                                    0.7
                                                                                           89
                                                                                                 0.5
                               4.3
                                     21
                                          13
                                              133540
                                                         91019
                                                                  96
                                                                        497
                                                                                         4566
                                                                                                13.1
               ArabiaSaudi
                                                                               1
                                                                                    0.0
                               2.5
                                               44609
                                                         19883
                                                                  42
                                                                        180
                                                                               2
                                                                                    0.8
                                                                                          906
                    Argelia
                                     34
                                          24
                                                                                                 3.0
                 Argentina
                               1.3
                                     22
                                          31
                                              278431
                                                         65962
                                                                 160
                                                                       1043
                                                                              22
                                                                                    0.1
                                                                                         1504
                                                                                                 3.5
                                              337909
                                                                 510
                                                                        933
                                                                              19
                  Australia
                               1.4
                                      6
                                          43
                                                        167155
                                                                                    0.0
                                                                                         5341
                                                                                                15.3
                               0.6
                                      6
                                          41
                                              216547
                                                         53259
                                                                 465
                                                                        304
                                                                              47
                                                                                         3301
                                                                                                 7.2
                    Austria
                                                                                   -0.4
                Bangladesh
                               2.0
                                     79
                                          42
                                               28599
                                                          9891
                                                                   2
                                                                        220
                                                                               6
                                                                                    4.1
                                                                                           64
                                                                                                 0.2
                    Bélgica
                               0.3
                                      8
                                          40
                                              250710
                                                         72236
                                                                 457
                                                                        917
                                                                              20
                                                                                   -0.3
                                                                                         5120
                                                                                                10.1
                     Benin
                               3.0
                                     95
                                          48
                                                 2034
                                                              6
                                                                   5
                                                                         26
                                                                              45
                                                                                    1.3
                                                                                           20
                                                                                                 0.1
                Bielrorrusia
                               0.4
                                     13
                                          49
                                               21356
                                                         31397
                                                                 190
                                                                        295
                                                                              31
                                                                                   -0.4
                                                                                         2392
                                                                                                 9.9
                    Bolivia
                               2.3
                                     69
                                          37
                                                 5905
                                                          2824
                                                                  35
                                                                        201
                                                                              45
                                                                                    1.2
                                                                                          373
                                                                                                 1.0
                      Brasil
                               1.6
                                     44
                                          35
                                              579787
                                                        260682
                                                                  75
                                                                        246
                                                                              66
                                                                                    0.6
                                                                                          718
                                                                                                 1.4
                   Bulgaria
                              -0.6
                                     15
                                          48
                                               11225
                                                        381333
                                                                 335
                                                                       1544
                                                                              33
                                                                                   -0.2
                                                                                         2438
                                                                                                 6.4
                  Camerún
                              2.9
                                                 8615
                                                                                          103
                                     56
                                          38
                                                          2740
                                                                   4
                                                                         38
                                                                              44
                                                                                    0.6
                                                                                                 0.2
                    Canadá
                                              573695
                                                        554227
                                                                 590
                                                                       1602
                                                                                         7854
                               1.3
                                      6
                                          45
                                                                              49
                                                                                   -1.1
                                                                                                14.4
                  Colombia
                               1.8
                                               70263
                                                         43354
                                                                 100
                                                                        174
                                                                              52
                                                                                    0.7
                                                                                          622
                                                                                                 1.8
                                     26
                                          37
                    Congo
                               3.1
                                     90
                                          43
                                                 1784
                                                           435
                                                                   8
                                                                         20
                                                                              58
                                                                                    0.2
                                                                                          331
                                                                                                 1.6
           Corea del Norte
                                                         38000
                                                                  47
                                                                              74
                                                                                         1129
                               1.8
                                          45
                                               12870
                                                                        687
                                                                                    0.0
                                                                                                11.2
                                     26
              Corea del Sur
                               0.9
                                     10
                                          40
                                              435137
                                                        164993
                                                                 415
                                                                        632
                                                                              66
                                                                                    0.1
                                                                                         2982
                                                                                                 6.6
```

```
In [ ]: rows, cols = df1.shape
```

Estandarizar los datos

Cálculo de matriz de distancias con norma usual sobre los datos estandarizados

```
distance_matrix = np.zeros((rows,rows))
for i in range(0, distance_matrix.shape[0]):
    for j in range(0, distance_matrix.shape[1]):
        distance_matrix[i][j] = euclidean(X_stand[i],X_stand[j])
D = pd.DataFrame(distance_matrix, index=df1.index, columns=df1.index)
D
```

Out[]:

Pais	Albania	Angola	ArabiaSaudi	Argelia	Argentina	Australia	Austria	Bangladesh
Pais								
rais								
Albania	0.000000	3.752513	6.030931	3.527386	3.309341	5.489904	3.312303	4.901438
Angola	3.752513	0.000000	6.268867	3.896872	4.757918	6.577615	5.535951	3.789780
ArabiaSaudi	6.030931	6.268867	0.000000	3.567421	4.469589	5.190911	5.661563	6.851553
Argelia	3.527386	3.896872	3.567421	0.000000	2.929080	5.435038	4.557730	4.185382
Argentina	3.309341	4.757918	4.469589	2.929080	0.000000	3.824587	3.120367	5.213299
Australia	5.489904	6.577615	5.190911	5.435038	3.824587	0.000000	2.946859	6.994499
Austria	3.312303	5.535951	5.661563	4.557730	3.120367	2.946859	0.000000	6.326376
Bangladesh	4.901438	3.789780	6.851553	4.185382	5.213299	6.994499	6.326376	0.000000
Bélgica	4.607470	6.164894	5.326790	4.858081	3.012241	1.709158	2.105569	6.626921
Benin	3.039147	1.621430	6.493453	4.064277	4.669275	6.472718	5.112193	3.544790
Bielrorrusia	2.741305	4.808254	5.857646	4.326536	3.431028	3.584179	2.238666	5.745261
Bolivia	2.101209	2.448090	5.433299	2.822211	3.430620	5.755907	4.217477	3.468933
Brasil	3.783482	5.138529	6.172855	4.726401	3.584200	5.330778	4.082009	5.771028
Bulgaria	4.961830	6.593824	7.164312	6.044946	4.054756	4.051269	4.014800	6.968986
Camerún	2.011646	2.508673	5.330601	2.799295	3.610613	5.920155	4.296617	4.051590
Canadá	7.949236	9.102662	7.584069	8.363009	6.276066	3.947964	5.577810	9.793485
Colombia	1.288551	3.680783	5.293859	2.919532	2.817597	5.023523	3.104766	4.371223

Albania

Pais

				g	J			g
Pa	is							
Cong	o 2.577407	2.188151	6.007697	3.958317	4.390937	6.238834	4.662920	4.680734
Corea de Nort	7 /1197 19	4.802033	5.859170	4.738049	3.757117	4.596372	3.367440	5.908987
Corea de Su	3 9042/5	5.974873	6.008146	5.163171	3.171085	3.196468	1.905280	6.531700
4)

Argelia Argentina Australia

Austria Bangladesh

Cálculo de los autovectores y autovalores de la matriz de distancias

Angola ArabiaSaudi

```
In [ ]:
        eig_values, eig_vectors = la.eig(distance_matrix)
        eig_values.round(2)
        array([ 88.34, -25.26, -10.92, -8.62, -6.66, -5.75, -4.83,
                                                                     -3.92,
Out[ ]:
               -3.54, -2.74, -2.59, -2.39, -2.06, -1.74, -0.89,
                                                                     -1.02,
                      -1.41, -1.27, -1.2 ])
               -1.52,
In [ ]:
        eig_vectors[0:2][:].round(2)
        array([[ 0.19, -0.16, -0.29, 0.08, 0.04, 0.04, 0.22, -0.09, -0.25,
                0.18, -0.04, -0.2, -0.31,
                                           0.47, 0.03, 0.43, -0.16, -0.34,
               -0.11, 0.01],
               [0.23, -0.28, 0.15, -0.23, -0.16, 0.15, -0.21, 0.24, 0.29,
                0.25, 0.29, 0.08, -0.03, 0.49, 0.01, -0.07, 0.05, 0.32,
                0.01, 0.25]])
```

Varianza explicada

Cálculo de las dos primeras coordenadas principales

3.969544

Albania 16.974222

Z1

Z2

Pais 20.526487 7.103094 Angola ArabiaSaudi 24.455931 -1.494481 18.963326 **Argelia** 3.483304 **Argentina** 16.907667 -1.119917 20.382949 Australia -7.751833 **Austria** 17.429380 -3.863033 Bangladesh 23.805541 5.553485 **Bélgica** 18.930396 -6.624970 19.115540 Benin 7.656742 Bielrorrusia 17.631891 -1.609926 **Bolivia** 16.534241 6.707736 19.865975 Brasil 0.091677 **Bulgaria** 22.071294 -6.018877 Camerún 16.937517 6.907735 **Canadá** 29.029397 -11.474034 Colombia 15.657647 3.966515 Congo 18.419828 6.895439 **Corea del Norte** 18.146257 0.438385 **Corea del Sur** 18.194200 -4.620041

Se puede identificar un outlier alrededor de $(29,\;-12)$, que corresponde al pais de Canadá

```
In []: plt.plot(new_df.Z1, new_df.Z2, 'o')
plt.show()

7.5
5.0
2.5
0.0
-2.5
-5.0
-7.5
-10.0
```

El país más cercano a Colombia es Albania, según la matriz de distancias:

```
distance_matrix = np.zeros((rows,rows))
for i in range(0, distance_matrix.shape[0]):
```

18

```
In [ ]: D.Colombia.sort_values()[0:2]
```

Name: Colombia, dtype: float64

Punto 2

Se tiene la matriz de distancia

$$\begin{bmatrix} 0 & 3 \\ 3 & 0 \end{bmatrix}$$

Como la matriz tiene dimensión 2×2 , la matriz de datos debe tener solo 2 registros. El número de columnas puede ser cualquiera, con tal de que la distancia entre los registros sea 3 ya que la matriz de distancia es simétrica. Se debe cumplir entonces

$$||X^{(1)} - X^{(2)}||_2 = 3$$

Con esto en cuenta, una matriz en particular que cumple esto es

$$\begin{bmatrix} 0 & 0 \\ 3 & 0 \end{bmatrix}$$

Punto 3

Out[]:		Sexo	Edad	IngresoDiario (miles)	PuntajeGastos(1-100)
	0	Female	47	120	16
	1	Male	21	15	81
	2	Female	20	16	6
	3	Female	23	16	77

	Sexo	Edad	IngresoDiario (miles)	PuntajeGastos(1-100)
4	Female	31	17	40
•••				
185	Male	30	99	97
186	Female	54	101	24
187	Male	28	101	68
188	Female	41	103	17
189	Female	36	103	85

190 rows × 4 columns

Cambiar a variable binaria la variable categórica Sexo

```
In [ ]:
    df3 = pd.get_dummies(df3, drop_first=True)
    df3
```

Out[]:		Edad	IngresoDiario (miles)	PuntajeGastos(1-100)	Sexo_Male
	0	47	120	16	0
	1	21	15	81	1
	2	20	16	6	0
	3	23	16	77	0
	4	31	17	40	0
	•••				
	185	30	99	97	1
	186	54	101	24	0
	187	28	101	68	1
	188	41	103	17	0
	189	36	103	85	0

190 rows × 4 columns

	Edad	IngresoDiario (miles)	PuntajeGastos(1-100)	Sexo_Male	Label
0	47	120	16	0	1
1	21	15	81	1	0
2	20	16	6	0	1
3	23	16	77	0	1
4	31	17	40	0	1
•••					
185	30	99	97	1	0
186	54	101	24	0	1
187	28	101	68	1	0
188	41	103	17	0	1
189	36	103	85	0	1

190 rows × 5 columns

La persona del primer registro pertence al cluster 1

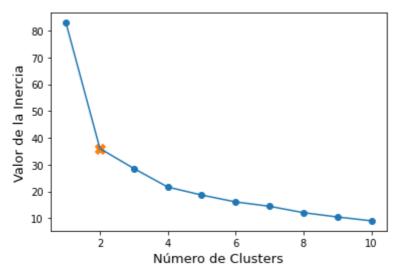
Número k de grupos óptimo

```
inertia_list = []
for num_clusters in range(1, 11):
    kmeans = KMeans(n_clusters=num_clusters, random_state=42)
    kmeans.fit(X)
    inertia_list.append(kmeans.inertia_)

plt.plot(range(1,11),inertia_list)
    plt.scatter(range(1,11),inertia_list)
    plt.scatter(2, inertia_list[1], marker='X', s=100)
    plt.xlabel("Número de Clusters", size=13)
    plt.ylabel("Valor de la Inercia", size=13)
    plt.show()
```

c:\Users\lenovo\anaconda3\lib\site-packages\sklearn\cluster_kmeans.py:881: UserWarn ing: KMeans is known to have a memory leak on Windows with MKL, when there are less chunks than available threads. You can avoid it by setting the environment variable OMP_NUM_THREADS=1.

warnings.warn(



Por el método del codo, un valor adecuado para el número de grupos es 2

```
In [ ]: kmeans = KMeans(n_clusters=2, random_state=42)
kmeans.fit(df3)

Out[ ]: KMeans(n_clusters=2, random_state=42)

In [ ]: df3['Label'] = kmeans.labels_
df3
```

Out[]:		Edad	IngresoDiario (miles)	PuntajeGastos(1-100)	Sexo_Male	Label
	0	47	120	16	0	0
	1	21	15	81	1	1
	2	20	16	6	0	0
	3	23	16	77	0	1
	4	31	17	40	0	0
	•••					
	185	30	99	97	1	1
	186	54	101	24	0	0
	187	28	101	68	1	1
	188	41	103	17	0	0
	189	36	103	85	0	1

190 rows × 5 columns

La persona del primer registro pertenece al cluster 0 cuando se definen 2 grupos

Punto 4

Demostrar que la esparanza condicional ${\cal E}[Y|X]$ es la solución al problema de minimización

$$f(x) = \frac{\operatorname{argmin}_{c} E((Y-c)^{2}|X=x)}{c}$$

Diferenciando f respecto c:

$$\frac{\partial f}{\partial c} = \frac{\partial}{\partial c} \left(E[(Y - c)^2 | X = x] \right) \tag{1}$$

$$\frac{\partial f}{\partial c} = \frac{\partial}{\partial c} \left(E[Y^2 | X = x] - 2cE[Y | X = x] + c^2 \right) \tag{2}$$

$$\frac{\partial f}{\partial c} = -2E[Y|X=x] + 2c = 0 \tag{3}$$

Lo que entrega

$$c = E[Y|X = x]$$

Esta c minimiza f porque la segunda derivada es mayor a 0.